TRAVAIL DE BACHELOR 2025

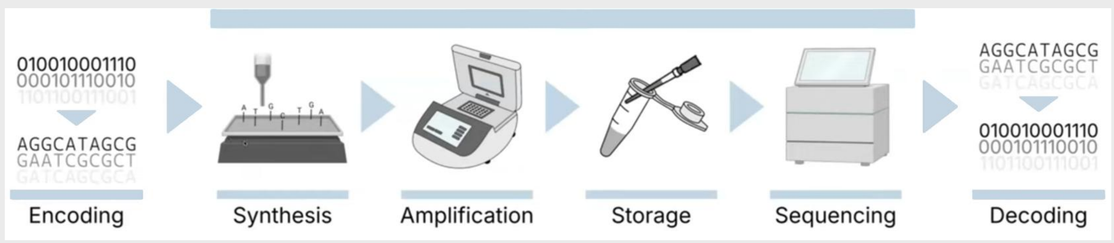
INFORMATIQUE ET SYSTÈMES DE COMMUNICATION

Accélération du regroupement de brins d'ADN sur FPGA



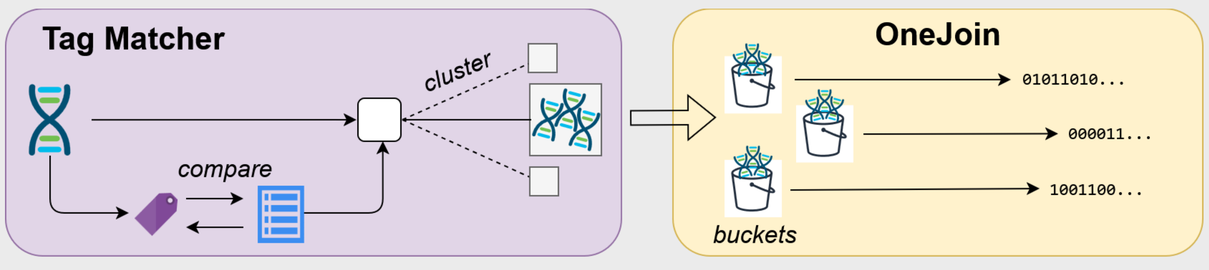
Description

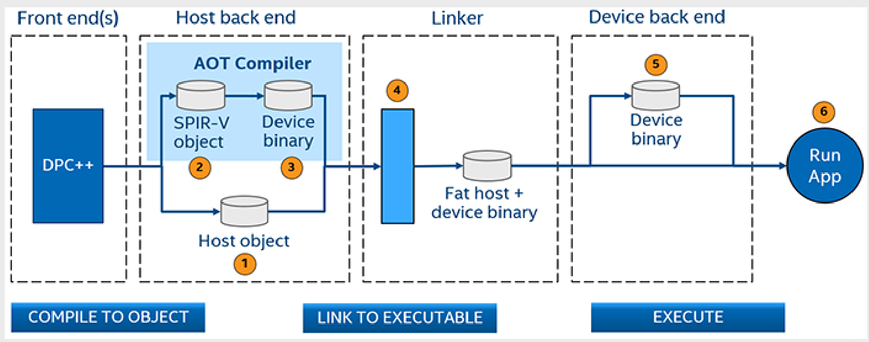
Dans le cadre du projet européen DNAMIC, qui vise à stocker des données dans de l'ADN synthétique pour remplacer les infrastructures polluantes actuelles, ce projet aborde un défi critique : le clustering rapide de séquences d'ADN après séquençage. Les erreurs de lecture (10%) et les mutations nécessitent de regrouper les copies d'un même brin original en calculant leur similarité à l'aide de la distance de Levenshtein.



Réalisation

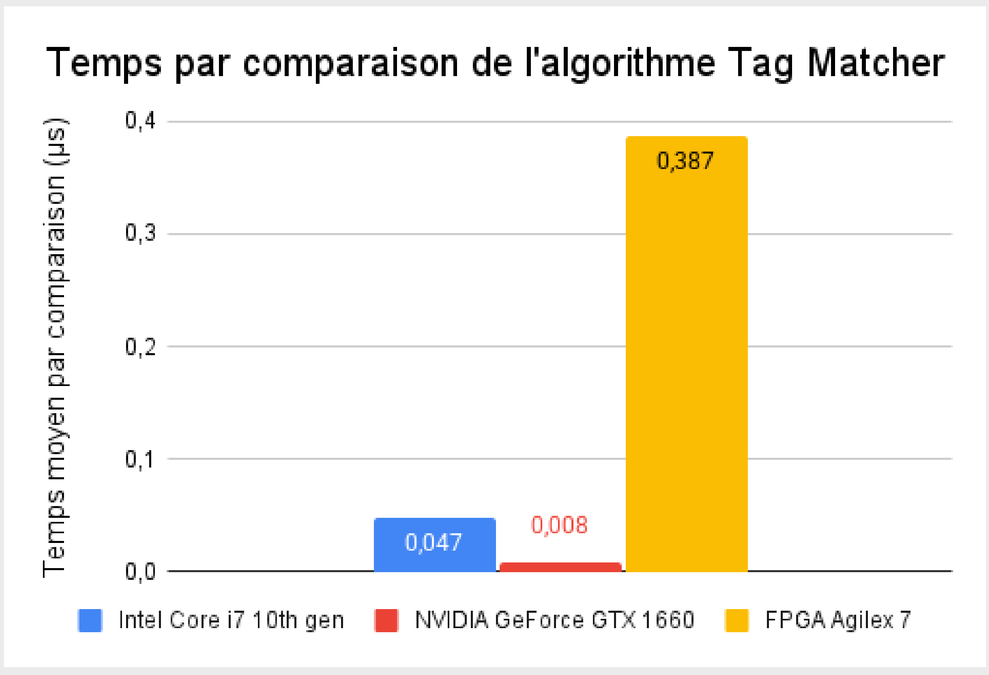
L'étude et l'implémentation de deux algorithmes de tri complémentaires en SYCL/DPC++ : un pré-filtrage par tags (Tag Matcher) et un clustering plus optimisé mais plus coûteux (OneJoin), ont permis le tri de centaines de milliers de brin en quelques µs. Cette approche High-Level Synthesis permet un développement unifié sur CPU, GPU et FPGA avec le même code C++, offrant ainsi la flexibilité aux ingénieurs du système d'archivage Yareta de réutiliser de réutiliser et d'adapter facilement le code.





Résultats

Après avoir maitrisé le flot de compilation SYCL/DPC++ pour CPU, GPU et FPGA, Tag Matcher atteint 99% de rappel et 88.6% de précision. OneJoin obtient lui 100% d'exactitude sur les datasets testés. Paradoxalement, le GPU surpasse le FPGA (~50x plus rapide), révélant que malgré la portabilité du code SYCL, l'optimisation architecture-spécifique reste cruciale pour exploiter pleinement les capacités de parallélisation des FPGAs.





Adrian SPYCHER

Sous la direction de Laurent Gantel

Hes·so GENÈVE
Haute Ecole Spécialisée de Suisse occidentale

hepia
Haute école du paysage, d'ingénierie et d'architecture de Genève